Présentation Cahier des Charges

Sonny Klotz - Jean-Didier Pailleux - Malek Zemni

UVSQ

01/06/2017

Introduction

Projet de L3 informatique UVSQ, remis par DCbrain.

- Projet découlant d'un thème : le **Big Data**.
- Analyse descriptives de données pour répondre au problème du **Big Data**.
- Utilisation de graphe de flux par DCbrain pour visualiser le réseau (détections d'erreurs, optimisation).
- **Objectif :** Fournir application web, outils permettent de charger des données, de les visualiser et les analyser.

Introduction

Plan

Architecture

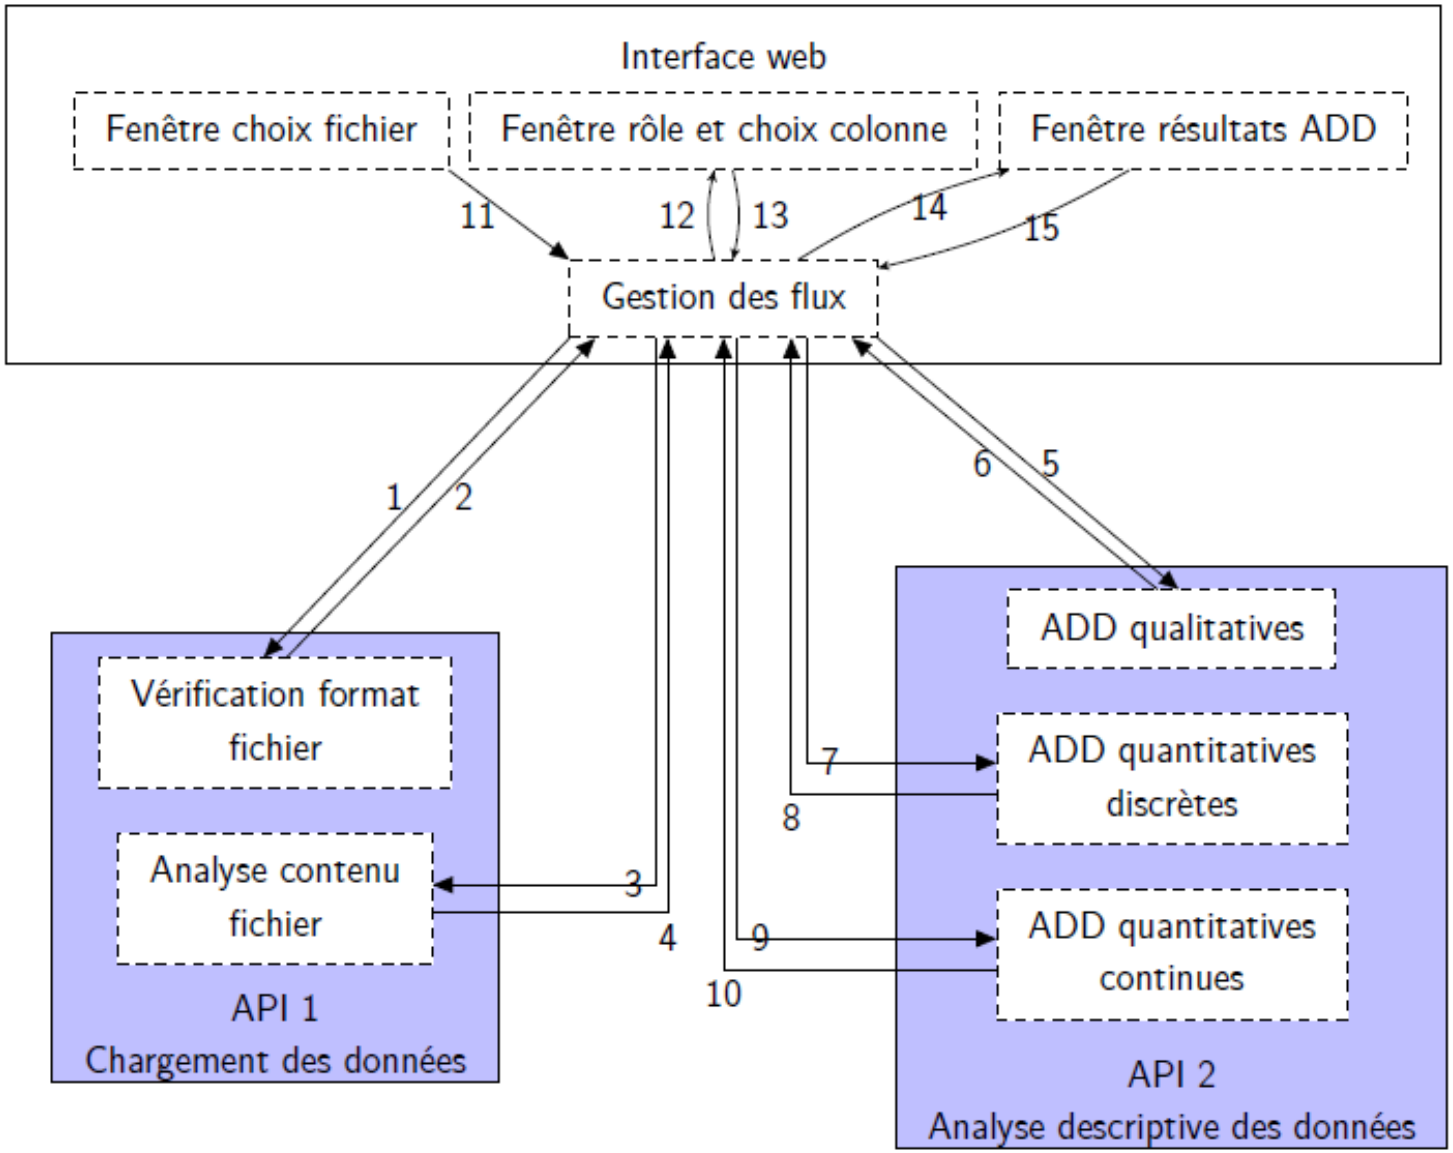

Architecture

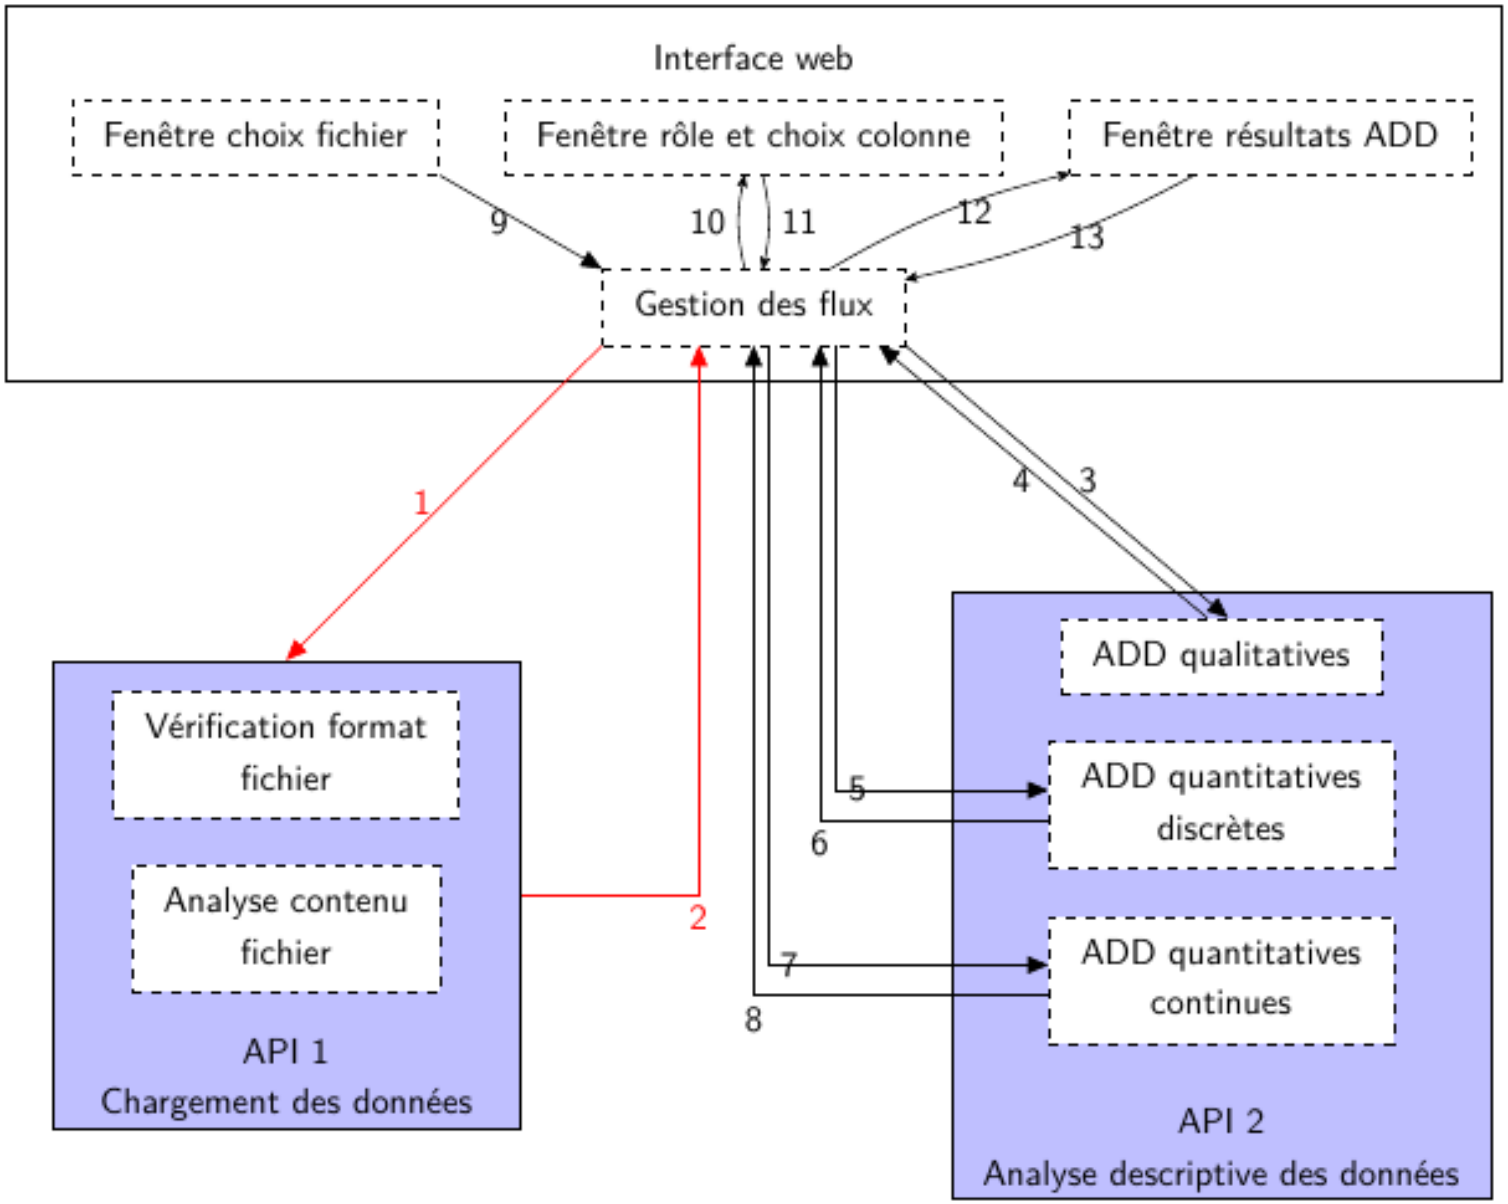

API 1 : Chargement des données

Vérification format fichier :

- Format csv
- Ouverture en lecture
- Texte brut ou formaté

API 1 : Chargement des données

Vérification format fichier :

- Format csv
- Ouverture en lecture
- Texte brut ou formaté

Analyse contenu fichier :

- Lecture des données du fichier ligne par ligne + stockage de ces données dans une **structure 1**
- Description des données de chaque colonne : type, nom et données erronées + stockage dans une **structure 2**.

Architecture

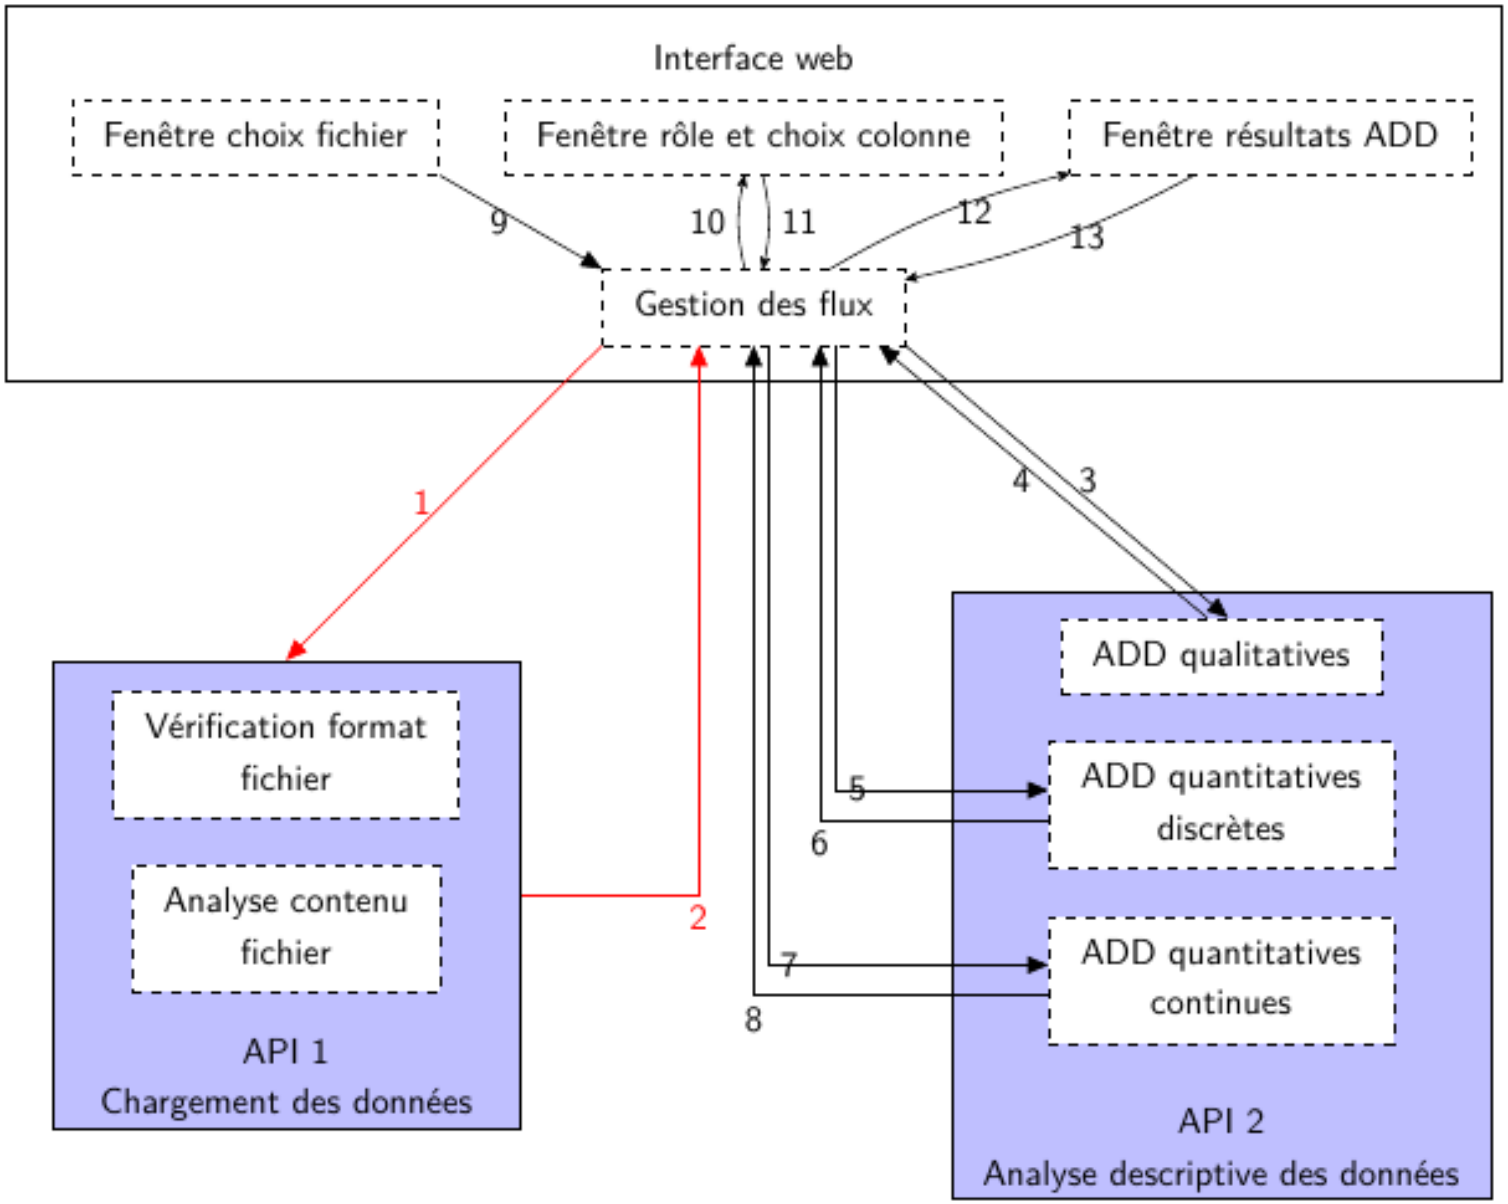

API 2 : Analyse descriptives des données

- **Données à analyser :** Données d'une colonne (Avec un possible filtrage).
- **Retours de l'analyse :** Informations statistiques et représentations graphiques.
- **ADD quantitatives continues :** Discrétisation des valeurs.

Architecture

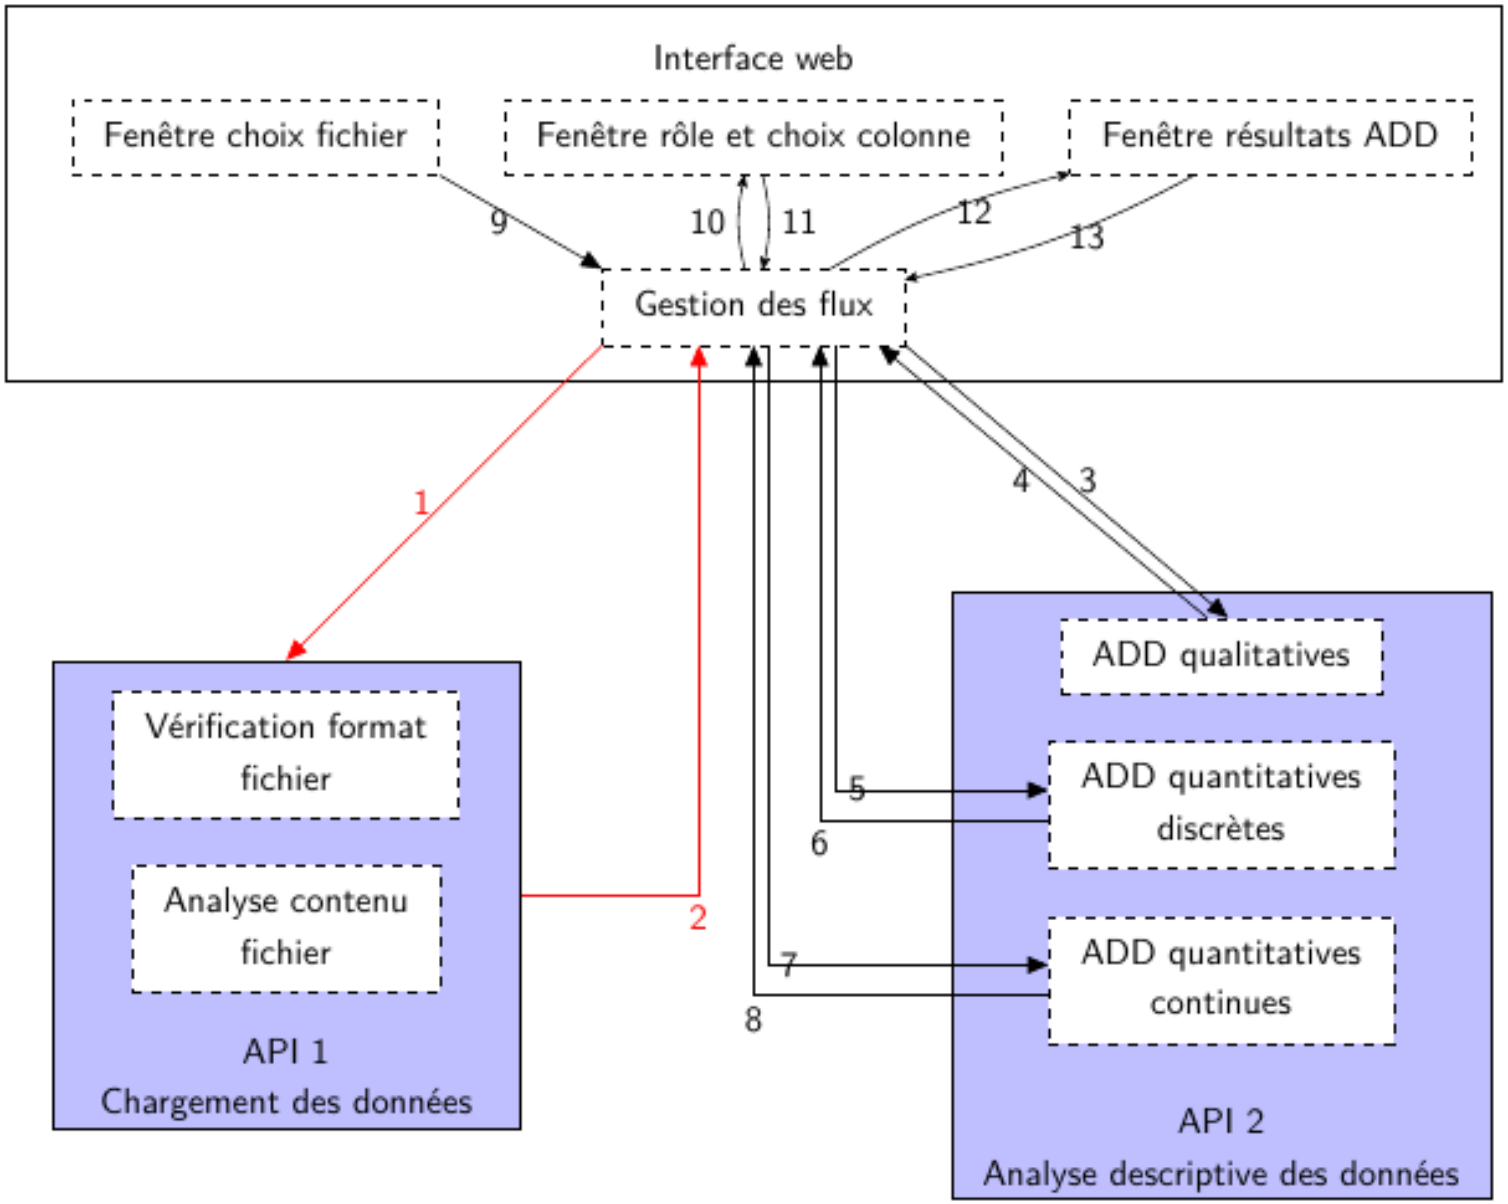

Interface web

Gestion des flux :

- **Flux d'exécution :** Gestion des branchements et arrêts de l'application en cas d'erreur(s).
- **Flux de données :** Rôle d'interface pour communiquer les données entre les différents modules

Interface web

Gestion des flux :

- **Flux d'exécution :** Gestion des branchements et arrêts de l'application en cas d'erreur(s).
- **Flux de données :** Rôle d'interface pour communiquer les données entre les différents modules

Fenêtre choix fichier :

- **Choix du fichier :** Parcours de l'arborescence de fichiers - Drag&Drop.

Fenêtre rôle et choix colonne :

- Affiche sous forme d'un tableau : nom des colonnes - nombre de lignes et de colonnes - un échantillon grâce à une navigation.
- Affichage des données erronés + description.
- Sélection et envoi d'une colonne de mesures pour analyse.

Fenêtre rôle et choix colonne :

- Affiche sous forme d'un tableau : nom des colonnes - nombre de lignes et de colonnes - un échantillon grâce à une navigation.
- Affichage des données erronés + description.
- Sélection et envoi d'une colonne de mesures pour analyse.

Fenêtre résultats ADD :

- Affichage des résultats d'analyse descriptive : informations statistiques + représentations graphiques.
- Fonctionnalité de retour en arrière pour analyser une nouvelle colonne.
- Fonctionnalité de téléchargement des résultats au format .csv

Plan

Outils, langages de programmation

Contraintes : sur le produit :

1. Fournir une application web.
2. Développé avec un langage de programmation compatible avec l'analyse de données.
3. Fournir des API pour le chargement et l'analyse de données.

Outils, langages de programmation

Contraintes : sur le produit :

1. Fournir une application web.
2. Développé avec un langage de programmation compatible avec l'analyse de données.
3. Fournir des API pour le chargement et l'analyse de données.

Outils et langages de programmation

- **Python :** adapté pour l'ADD et le développement d'applications web
- **Flask :** framework web Python
- **HTML et CSS :** présentation et mise en forme des pages web
- **JavaScript :** dynamiser les pages web
- **jQuery :** gestion des événements et **Ajax**
- **c3js :** module de représentations graphiques
- **Sphinx :** framework Python, génération de documentation

Plan

Fonctionnement de l'application

Fichier CSV : contenu structuré établi par le client : décrit par des colonnes aux types prédéfini

timestamp	parent	enfant	mesure 1	mesure 2
January 1st 2017, 15 :00 :00.000	102	95	26644.235	176.253

Fonctionnement de l'application

Fichier CSV : contenu structuré établi par le client : décrit par des colonnes aux types prédéfini

timestamp	parent	enfant	mesure 1	mesure 2
January 1st 2017, 15 :00 :00.000	102	95	26644.235	176.253

API chargement de données gère des fichiers CSV quelconques :

- Lignes avec données en moins ou en trop
- Colonnes désordonnées
- Délimiteur quelconque

Fonctionnement de l'application

Interface web : gère l'interaction avec l'utilisateur

1. Importation du fichier CSV
2. Visualisation du contenu + erreurs
3. Application de filtres + attribution rôles colonnes
4. Envoi d'une colonne pour l'analyse
5. Affichage des résultats de l'analyse : graphes et valeurs statistiques
6. Téléchargement des résultats de l'analyse

Fonctionnement de l'application

Interface web : gère l'interaction avec l'utilisateur

1. Importation du fichier CSV
2. Visualisation du contenu + erreurs
3. Application de filtres + attribution rôles colonnes
4. Envoi d'une colonne pour l'analyse
5. Affichage des résultats de l'analyse : graphes et valeurs statistiques
6. Téléchargement des résultats de l'analyse

APIs : réutilisables par le client, gèrent le traitement des données

- **Chargement de données :** préparation du contenu du fichier pour l'affichage
- **Analyse descriptive des données :** analyse des colonnes du fichier

Plan

Paradigme client / serveur

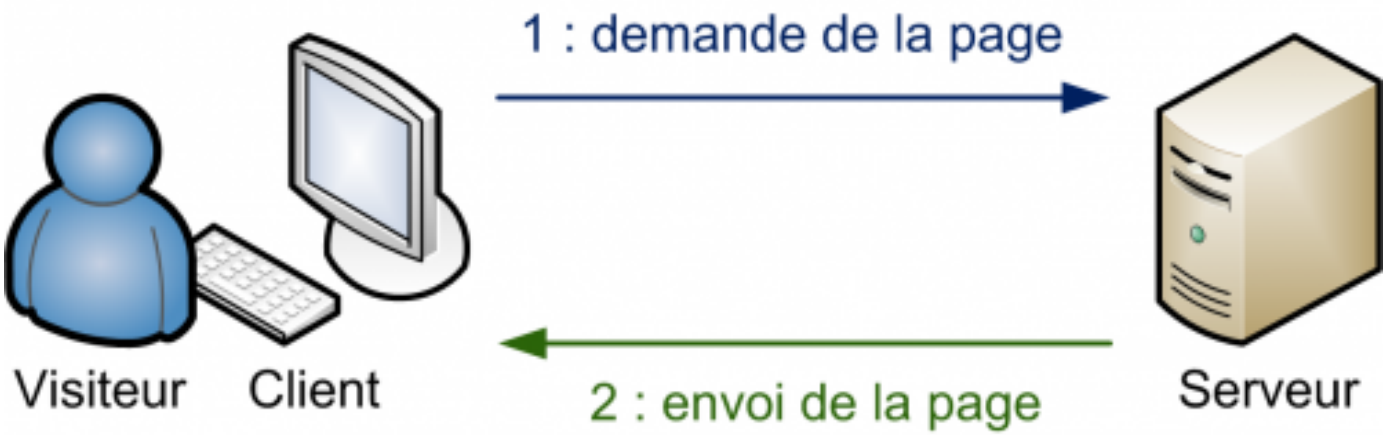

- **Client** : Navigateur Web -> Requête URL au Serveur.
- **Serveur** : Réception de la requête -> retour de la page demandée.
- **Flask** : framework web choisi.

Templates HTML

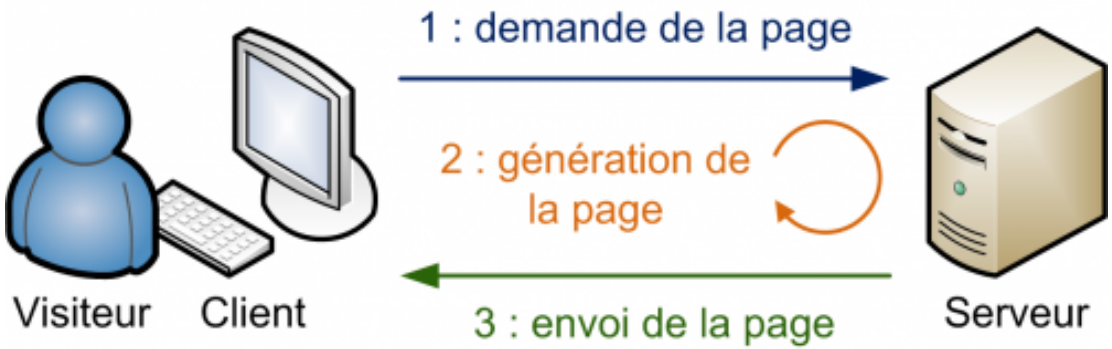

- **Template** : Page html formatée générique, avec des balises.
- **Flask** :
  Création de la page html finale.
  Balises peuvent contenir du code Python.

Enjeu

Pages dynamiques.

Les applets

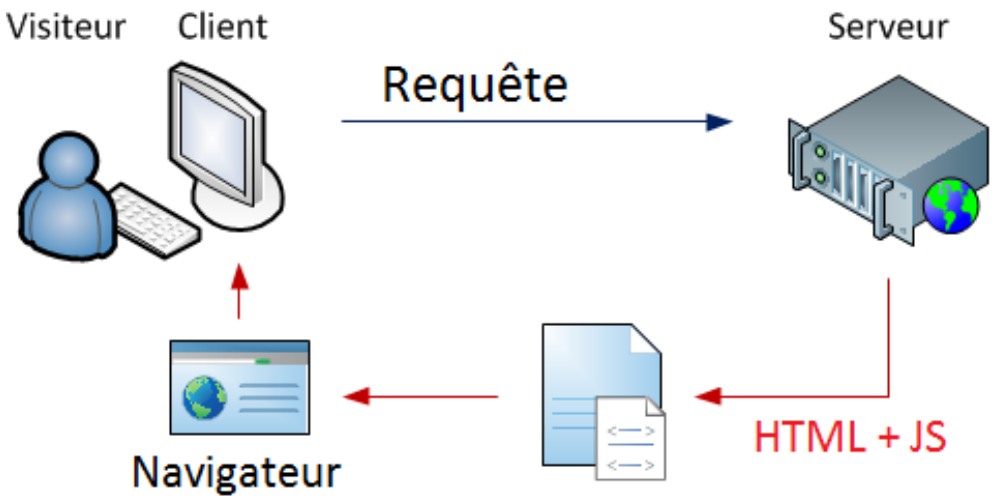

1. Balises <script> pour HTML.
2. Code exécuté côté client : ***JavaScript***

Dynamisme : Animations, programmation évènementielle, Html modifié en direct.

Enjeu

Circulation des données nécessaire : Côté client <=> Côté serveur.

Ajax (Asynchronous JavaScript and Xml)

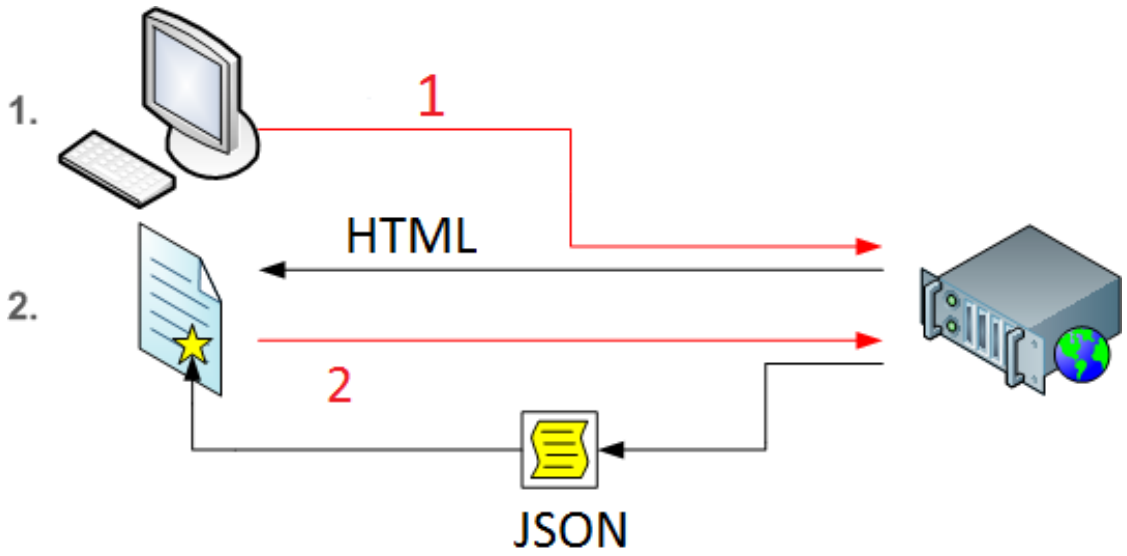

- Rafraichissement **partiel** de la page.
- JSON : syntaxe des objets JavaScript, légère.
- Mécanisme asynchrone : fonctions **callback**

- **Divergence avec les spécifications**
  Problème : Utilisation des fichiers.
  Caractéristique : Indépendance ressources Client / Serveur.
  Solution : envoi Ajax.

- **Divergence avec les spécifications**
  Problème : Utilisation des fichiers.
  Caractéristique : Indépendance ressources Client / Serveur.
  Solution : envoi Ajax.

- **Séries temporelles**
  Problème : Affichage incohérent.
  Caractéristique : Plusieurs mesures à un temps donné.
  Solution : Une série temporelle par arc distinct.

- **Divergence avec les spécifications**
  Problème : Utilisation des fichiers.
  Caractéristique : Indépendance ressources Client / Serveur.
  Solution : envoi Ajax.

- **Séries temporelles**
  Problème : Affichage incohérent.
  Caractéristique : Plusieurs mesures à un temps donné.
  Solution : Une série temporelle par arc distinct.

- **Performances (non résolu)**
  Problème : Affichage du jeu de données.
  Caractéristique : Complexité non-linéaire.
  Solution (éventuelle) : Module JavaScript personnel.

- **Divergence avec les spécifications**
  Problème : Utilisation des fichiers.
  Caractéristique : Indépendance ressources Client / Serveur.
  Solution : envoi Ajax.

- **Séries temporelles**
  Problème : Affichage incohérent.
  Caractéristique : Plusieurs mesures à un temps donné.
  Solution : Une série temporelle par arc distinct.

- **Performances (non résolu)**
  Problème : Affichage du jeu de données.
  Caractéristique : Complexité non-linéaire.
  Solution (éventuelle) : Module JavaScript personnel.

Plan

Organisation interne du groupe

Module	Malek	Sonny	Jean-Didier
Gestion des flux			x
Fenêtre choix fichier			x
Fenêtre rôle et choix colonne	x		
Fenêtre résultats ADD		x	
ADD qualitatives			x
ADD quantitatives discrètes		x	
ADD quantitative continues		x	
Vérification format fichier	x		
Analyse contenu fichier	x		

- Groupe de trois personnes.
- Planning respecté.
- Travail en groupe.

Plan

Coûts

Module	Estimation	Coût final
Gestion des flux	15	**98**
Fenêtre choix fichier	30	**72**
Fenêtre rôle et choix colonne	65	**180**
Fenêtre résultats ADD	100	**200**
ADD qualitatives	60	53
ADD quantitatives discrètes	100	89
ADD quantitatives continues	85	93
Vérification format fichier	30	35
Analyse contenu fichier	60	70
Coût Total	**545**	**850**

Coûts

Justifications

Ajax : Charge supplémentaire code.

Séries temporelles : Deux fonctionnalités supplémentaires.

Filtrage des valeurs : Demandées après l'écriture du cahier des charges.

Plan

Conclusion

Support :

Masse de données collectées sur un ***réseau physique*** assimilé à un ***graphe de flux***.

Applet :

Traitement des données à l'aide d'analyses descriptives.

Résultats : statistiques et visuels.

Améliorations possibles :

Interface-web : performances de l'affichage.

API extensibles :

- ADD : analyses multidimensionnelles et nouvelles représentations graphiques.